



中国科学院大学
University of Chinese Academy of Sciences

Deep Learning

Transformer

Xinfeng Zhang (张新峰)

School of Computer Science and Technology

University of Chinese Academy of Sciences

Email: xfzhang@ucas.ac.cn



计算机科学与技术学院

SCHOOL OF COMPUTER SCIENCE AND TECHNOLOGY



提纲

- 注意力机制
- Transformer
- GPT系列模型
- BERT系列模型
- Swin Transformer
- Transformer的主要应用
- 中英文术语对照



6


Transformer的主要应用

自然语言处理领域

- ❑ 机器翻译
- ❑ 自动文本摘要
- ❑ 机器阅读理解

机器翻译

- 2019年，Mike Lewis等人提出了BART模型，该模型使用标准的基于Transformer的神经机器翻译架构，训练了一个结合双向编码器和自回归解码器的模型，同时它也是一个去噪自编码器，适用于非常广泛的序列到序列模型的构建。



机器翻译

- 不同于GPT，BART将激活函数修改为GeLU。
- BART的基本模型（Base Model）包含6层编码器和解码器，大模型（Large Model）包含12层编码器和解码器。
- BART通过破坏原始文档然后进行重建来训练，与现有针对特定噪声方案量身定制的去噪自编码器不同的是，BART允许使用任何类型的文档破坏方式。


机器翻译

□ BART提出了以下几种加入噪声的方式：

- 单词掩码（Token Masking）：选择随机单词并替换成[MASK]标记。
- 单词删除（Token Deletion）：从输入中随机删除单词。
- 文本填充（Text Infilling）：对一些文本跨度进行采样，跨度长度来自泊松分布，每个跨度被一个[MASK]标记取代。
- 句子排列（Sentence Permutation）：将输入序列按照完整的停止符划分成句子之后，随机重排序。
- 文件旋转（Document Rotation）：一个标记被均匀的随机选择，从该标记开始的文件被旋转。

机器翻译

- ❑ BART将编码器嵌入层替换为一个新的随机初始化编码器，它训练新的编码器将外来的词映射到BART对噪声具有鲁棒性的输入中。新的编码器可以使用与原始BART独立的词汇表。
- ❑ 接下来，使用两个步骤训练源编码器：首先冻结大部分的BART参数，只更新随机初始化源编码器、BART位置嵌入向量和BART编码器第一层自注意力机制的输入投影矩阵；接着使用少量迭代训练所有模型参数。



自动文本摘要

- ❑ BERTSum的核心是新定义的编码器，原始BERT模型的输入是句子对，而BERTSum输入的是多个句子，在每个输入句子之前加入[CLS]标记用来标记独立的句子，同时使用段向量 E_A 标记奇数句子， E_B 标记偶数句子。
- ❑ 在基于BERT的生成式模型中，使用编码器-解码器结构进行摘要的生成，编码器采用的是预训练好的BERTSUM，而解码器则是一个6层的随机初始化的Transformer。
- ❑ 但是，编码器和解码器之间存在不平衡的问题，编码器已经训练过，而解码器需要从头开始训练，为了克服这个问题，设计了一个将编码器和解码器分开微调的机制。此外，还尝试首先在抽取式任务上微调，然后再在生成式任务上微调，以实现两个阶段的平衡问题。

自动文本摘要

□ 原始BERT

输入单词

[CLS] sent one [SEP] 2nd sent [SEP] sent again [SEP]

词向量

$E_{[CLS]}$ E_{sent} E_{one} $E_{[SEP]}$ E_{2nd} E_{sent} $E_{[SEP]}$ E_{sent} E_{again} $E_{[SEP]}$

段向量

E_A E_A E_A E_A E_A E_A E_A E_A E_A E_A

位置向量

E_1 E_2 E_3 E_4 E_5 E_6 E_7 E_8 E_9 E_{10}

Transformer


最终语义表示

$T_{[CLS]}$ T_{sent} T_{one} $T_{[SEP]}$ T_{2nd} T_{sent} $T_{[SEP]}$ T_{sent} T_{again} $T_{[SEP]}$


自动文本摘要

□ BERTSum

输入单词



词向量



段向量



位置向量




Transformer

最终语义表示



机器阅读理解

- 具体来说，SG-Net将句法依赖引入到自注意力网络（Self-attention Networks, SAN）中，提出语法引导的自注意力机制（Syntax-guided Self-attention）。SG-Net就是由这个语法引导的自注意力机制和原始的Transformer编码器中的自注意力机制通过对偶语义聚合而成。



机器阅读理解

- ❑ SG-Net专注两种类型的机器阅读理解任务，分别是基于片段选择的机器阅读理解任务和基于多项选择的机器阅读理解任务，二者分别可以被描述为 $\langle P, Q, A \rangle$ 和 $\langle P, Q, C, A \rangle$ ，其中，P表示原文，Q表示问题，A表示答案，C表示选项。
- ❑ 对于基于片段选择的机器阅读理解任务，在SQuAD 2.0数据集上实现了SG-Net模型，模型能够预测原文中的开始和结束位置，并提取原文P的片段作为答案A，当问题无法被回答时返回空字符串。
- ❑ 对于基于多项选择的机器阅读理解任务，在RACE数据集上训练并测试了SG-Net模型，该数据集要求给定一个段落和问题，从一组候选答案中选择正确答案。

机器阅读理解

- ❑ SG-Net采用BERT作为Transformer编码器的具体实现，输入被送到BERT模型中，从而得到语义向量表示 H ，然后将其传递到SG-Net中，得到语法增强的语义向量表示 $\tilde{H}$ 。
- ❑ 对于基于片段选择的机器阅读理解任务， $\tilde{H}$ 被送入线性层并通过Softmax获得开始和结束位置的概率分布。
- ❑ 对于基于多项选择的机器阅读理解，将 $\tilde{H}$ 送到分类器中，预测多项选择任务的标签。

计算机视觉领域

□ 图像分类

□ 目标检测


图像分类

- ❑ 在传统的卷积神经网络中，卷积层和池化层通常用于从图像中提取特征，然后通过全连接层进行分类。
- ❑ 但是，CNN在处理长序列数据时存在一些问题，比如当序列很长时，会导致梯度消失问题。
- ❑ 此时，Transformer模型就可以充分发挥其优势，通过自注意力机制来捕捉序列中的相关性，缓解梯度消失问题。

图像分类

- ❑ 在图像分类任务中，可以将图像中的每个像素或者每个图块看作一个序列，然后使用Transformer模型进行图像分类。
- ❑ ViT模型将图像分割成固定大小的图块（Patch），然后将每个图块展开成一个序列，接着通过Transformer模型进行特征提取和分类。
- ❑ ViT模型在ImageNet等图像分类任务中表现出了很好的效果。

图像分类



图像分类

- ViT模型首先通过分块和降维操作对图片进行预处理，具体地，首先把 $x \in \mathbb{R}^{H \times W \times C}$ 的图像变成一个 $x_p \in \mathbb{R}^{N \times (P^2 \times C)}$ 的2D图块。它可以看作是一系列的展平的2D图块序列，这个序列中一共有 $N = HW/P^2$ 个展平的2D图块，每个图块的维度是 $(P^2 \times C)$ 。
- 在得到视觉图像的图块之后，需要进一步对每个向量都做一个线性变换（即全连接层），压缩后的维度为d。

图像分类

- ViT没有采用原始Transformer的位置编码方式，而是直接设置为可学习的位置编码（Positional Encoding）。
- 在进行图块嵌入（Patch Embedding）之后，图像序列将进入ViT的Encoder进行前向传输，这个过程可以公式化为：

$$\mathbf{z}_0 = [\mathbf{x}_{class}; \mathbf{x}_p^1 \mathbf{E}; \mathbf{x}_p^2 \mathbf{E}; \dots; \mathbf{x}_p^N \mathbf{E}] + \mathbf{E}_{pos} \quad (1)$$

$$\mathbf{z}'_l = \text{MSA}(\text{LN}(\mathbf{z}_{l-1})) + \mathbf{z}_{l-1}, \quad l = 1, 2, \dots, L \quad (2)$$


$$\mathbf{z}_l = \text{MLP}(\text{LN}(\mathbf{z}'_l)) + \mathbf{z}'_l, \quad l = 1, 2, \dots, L \quad (3)$$

$$\mathbf{y} = \text{LN}(\mathbf{z}_L^0) \quad (4)$$




图像分类

- ❑ 公式(1)表示图块编码和位置编码过程，其中 E 是线性变换矩阵且 $E \in \mathbb{R}^{(P^2 \times C) \times d}$ ， $E_{pos} \in \mathbb{R}^{(N+1) \times d}$ ， x_{class} 为人为增加的一个可学习的分类向量。
- ❑ 公式(2)表示Transformer编码器中的多头自注意力（Multi-head Self-attention）、残差连接与层归一化（Add & Norm）过程，重复 L 次。
- ❑ 公式(3)表示Transformer编码器中前馈神经网络（Feed Forward Network）、残差连接与层归一化（Add & Norm）过程，重复 L 次。
- ❑ 公式(4)表示进行层归一化。

图像分类



Swin Transformer vs. ViT



目标检测


- ❑ 传统的目标检测模型，如Fast R-CNN、YOLO等，通常都是基于卷积神经网络构建的，它们使用卷积层从图像中提取特征，并使用后续层进行目标检测。
- ❑ 但是，卷积神经网络在处理长序列数据时存在一些问题，比如当序列很长时，模型会变得很深，导致梯度消失问题。
- ❑ 而Transformer模型通过自注意力机制来捕捉序列中的相关性，缓解了梯度消失问题，并且可以在序列较长时保持较高的精度。

目标检测

- ❑ 在目标检测任务中，可以将图像中的每个像素或者图块看作一个序列，然后使用Transformer模型进行目标检测。
- ❑ 目标检测Transformer（Detection Transformer, DETR）模型使用Transformer模型从整个图像中预测所有的目标边框和类别，而不是使用卷积神经网络提取特征再通过区域建议网络（Region Proposal Network, RPN）生成目标边框。
- ❑ DETR模型在COCO数据集上取得了很好的效果，在目标检测任务的准确率和运行时间上与Faster RCNN相当。
- ❑ DETR使用端到端（End-to-End）的方式实现目标检测。

目标检测

□ DETR分为四个部分：骨干网络、编码器、解码器和预测头



目标检测

- 首先，DETR采用了CNN作为骨干网络（Backbone）来处理 $x_{img} \in \mathbb{R}^{3 \times H_0 \times W_0}$ 的图像，将它转换为 $f \in \mathbb{R}^{C \times H \times W}$ 的特征图。
- 其次，得到图像特征 $f \in \mathbb{R}^{C \times H \times W}$ 后，DETR使用Transformer编码器对图像特征 f 进行编码与建模。
- 然后，编码器使用了原始的多头自注意力机制（Multi-head Self Attention, MSA）来进行序列之间的关系建模，公式为：

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V$$

目标检测

□ 原始Transformer中的位置编码为：

$$PE_{(pos,2i)} = \sin(\frac{pos}{10000^{2i/d}})$$

$$PE_{(pos,2i+1)} = \cos(\frac{pos}{10000^{2i/d}})$$

□ 原始Transformer只考虑x方向的位置编码，但是DETR考虑了x、y两个方向的位置编码，因为图像特征是2D特征。因此，DETR中的位置编码为：

$$PE_{(pos_x,2i)} = \sin(\frac{pos_x}{10000^{2i/d}})$$

$$PE_{(pos_x,2i+1)} = \cos(\frac{pos_x}{10000^{2i/d}})$$


$$PE_{(pos_y,2i)} = \sin(\frac{pos_y}{10000^{2i/d}})$$

$$PE_{(pos_y,2i+1)} = \cos(\frac{pos_y}{10000^{2i/d}})$$

目标检测

- ❑ 与原始Transformer不同，DETR的位置编码向量需要加入到每个编码器层中。在编码器内部位置编码仅作用于Query和Key，即只与Query和Key相加，Value不做任何处理。
- ❑ DETR的解码器主要有两个输入：一个是Transformer编码器的输出与位置编码之和，一个是目标查询（Object Queries）。
- ❑ 目标查询是一个维度为 $(100, b, 256)$ 的可学习张量，目标查询矩阵内部学习建模了100个物体之间的全局关系。
- ❑ DETR的Transformer解码器一次性处理全部的目标查询（Object Queries），即一次性输出全部的预测（Predictions），而不像原始的Transformer从左到右一个词一个词地输出。

目标检测



目标检测

- ❑ DETR最大特点是将目标检测问题转化为无序集合的预测问题。DETR输出一组N个固定大小的预测，其中N比图像中的目标数量要大。
- ❑ DETR损失函数产生了预测对象和真值（Ground Truth）之间的最佳二分匹配，然后优化特定对象（边界框）的损失。
- ❑ 用 y 来表示对象的真值（Ground Truth）集合，用 $\hat{y}$ 来表示N个预测的集合，为了找到这两个集合之间的二分匹配，寻找代价最低的n个元素的排列 $\hat{\sigma} \in S_N$ ，如下所示：

$$\hat{\sigma} = \operatorname{argmin}_{\sigma} \sum_i^N L_{\text{match}}(y_i, \hat{y}_{\sigma(i)})$$

多模态领域

- ❑ Transformer在多模态领域，如图像描述（Image Captioning）、视觉问答（Visual Question Answering）和文本生成图像（Text-to-Image Generation）等任务中都有很多应用，
- ❑ 我们主要介绍Transformer在图像描述任务中的应用。

多模态领域

- ❑ 基于深度学习的图像描述方法大多采用“编码器-解码器（Encoder-Decoder）”结构，其中编码器用于提取给定图像的视觉特征，而解码器用于将视觉特征解码为文本描述。
- ❑ 早期的方法常采用卷积神经网络（如VGG-16、ResNet等）作为编码器，循环神经网络（如GRU、LSTM等）作为解码器，之后目标检测网络（如Faster R-CNN）被引入作为编码器提取图像区域级特征而非网格特征，这些方法均可归类于CNN-RNN类方法。
- ❑ Transformer模型的成功也促使了研究人员探索其在图像描述任务上的应用，进而出现了CNN-Transformer类方法与Transformer-Transformer类方法。


CNN-Transformer类方法

- ❑ Transformer的提出最初是作为语言模型应用于自然语言处理领域任务，针对图像描述任务，一个很直观的改进思路则是将CNN-RNN中的解码器由RNN替换为Transformer，将此类方法称为CNN-Transformer类方法
- ❑ X-Transformer、M2Transformer、RSTNet和DLCT等工作均属于此类方法，这里以M2Transformer为例进行介绍。

CNN-Transformer类方法

- M2Transformer的整体框架由三部分组成：骨干编码器（Backbone Encoder）、记忆增强编码器（Memory-Augmented Encoder）和网格解码器（Meshed Decoder）。
 - 其中骨干编码器采用Faster R-CNN提取图像的区域特征，记忆增强编码器和网格解码器均采用Transformer结构，记忆增强编码器视为骨干编码器的扩展结构，旨在对图像区域特征进行语义增强，网格解码器则用于生成文本描述。

CNN-Transformer类方法



CNN-Transformer类方法

- 给定RGB图像 I ，M2Transformer模型的前向流程可以表示如下：

$$X = \text{BackboneEncoder}(I)$$

$$\tilde{X}_1, \tilde{X}_2, \dots, \tilde{X}_N = \text{Memory-AugmentedEncoder}(X)$$

$$\tilde{Y} = \text{MeshedDecoder}(\tilde{X}_1, \tilde{X}_2, \dots, \tilde{X}_N)$$

- 在M2Transformer中，记忆增强编码器和网格解码器均采用了Transformer结构，其核心为多头自注意力层（Multi-head Self-attention, MSA），计算公式如下：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V}$$

$$\text{MSA}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)$$

$$\text{head}_i = \text{Attention}(\mathbf{Q}^i, \mathbf{K}^i, \mathbf{V}^i), \quad i = 1, 2, \dots, h$$

CNN-Transformer类方法

- M2Transformer在自注意力原有K和V的基础上，引入了额外的“记忆槽”（Memory Slots）用于对先验信息进行编码，并且为了强调先验信息是独立于输入X的，“记忆槽”被建模为可训练的参数矩阵。相应输入与输出的计算公式如下：

$$X' = \text{LayerNorm}(MSA(W_q X, K, V) + X)$$

$$K = [W_k X, M_k], V = [W_v X, M_v]$$

$$\tilde{X} = \text{LayerNorm}(\text{FeedForward}(X') + X')$$


- 其中， $M_k, M_v \in \mathbb{R}^{n_m \times D}$ 即为可学习的“记忆槽”参数，FeedForward层由带有ReLU激活函数的两个线性层组成，可表示如下：

$$\text{FeedForward}(x) = W_2 \text{ReLU}(W_1 x)$$

- 其中， $W_1 \in \mathbb{R}^{(4D) \times D}$ 和 $W_2 \in \mathbb{R}^{D \times (4D)}$ 为两个线性层的可学习参数矩阵。

CNN-Transformer类方法

- 记忆增强编码器由多个上述编码层结构按顺序堆叠组成，第 i 层的输出作为第 $(i+1)$ 层的输入，相当于创建了图像区域之间关系的多级编码，因此 N 个编码层的堆叠将产生 N 个输出 $\{\tilde{X}_1, \tilde{X}_2, \dots, \tilde{X}_N\}$ 作为图像的多级区域特征。



CNN-Transformer类方法

- 网格解码器使用已生成的单词以及记忆增强编码器输出的多级区域特征作为输入，表示如下：

$$Y' = \text{LayerNorm}(\text{MSA}(W_q^s Y, W_k^s Y, W_v^s Y) + Y)$$

$$Y'' = \sum_{i=1}^N \alpha_i \odot \text{LayerNorm}(\text{MSA}(W_q^c Y, W_k^c \tilde{X}_i, W_v^c \tilde{X}_i) + Y)$$

$$\tilde{Y} = \text{LayerNorm}(\text{FeedForward}(Y'') + Y'')$$

- 其中， $W_q^s, W_k^s, W_v^s \in \mathbb{R}^{D \times D}$ 为掩码自注意力（Masked Self-attention）层中可学习参数， $W_q^c, W_k^c, W_v^c \in \mathbb{R}^{D \times D}$ 为跨模态注意力（Cross Attention）层中可学习参数， $\odot$ 表示逐元素相乘操作（Element-wise Product）。


CNN-Transformer类方法

- 与原始Transformer解码器的不同之处在于跨模态注意力层，网格解码器同时利用了图像的多级区域特征，构成与记忆增强编码器各层输出之间的网状连接，并进行了门控加权，门控权重 α_i 的计算公式如下：

$$\alpha_i = \sigma(W_i[Y, \text{LayerNorm}(\text{MSA}(W_q^c Y, W_k^c \tilde{X}_i, W_v^c \tilde{X}_i) + Y)] + \underline{b}_i)$$

– 其中， $W_i \in \mathbb{R}^{D \times 2D}$ 为可学习参数， $\sigma(\cdot)$ 为Sigmoid激活函数。

CNN-Transformer类方法



Transformer-Transformer类方法


- ❑ CNN-RNN类方法和CNN-Transformer类方法大多采用Faster R-CNN提取图像区域级特征，但是Faster R-CNN需要在额外数据集上进行预训练，导致图像描述被分割为两个独立的子任务从而无法进行端到端（End2End）的训练，限制了图像描述任务的潜在应用。
- ❑ 针对此问题，研究人员开始探索完全基于Transformer结构的图像描述模型，此类方法可总结为Transformer-Transformer类方法，PureT、PTSN、ViTCAP等模型均属于此类方法。
- ❑ 这里主要介绍PureT模型。

CNN-Transformer类方法

□ PureT模型包含三个部分：

- 骨干编码器（Backbone Encoder）：用于从输入图像中提取网格级特征。
- 增强编码器（Refining Encoder）：用于捕获图像网格特征的模态内关系以增强特征的表征能力，可视为图像基础编码器的扩展。
- 解码器（Decoder）：用于将增强网格特征解码为描述语句。此外还设计了一个预融合模块（Pre-Fusion），用于增加视觉模态信息与文本模态信息之间的交互。


Transformer-Transformer类方法




Transformer-Transformer类方法

- ❑ PureT中使用了原始的多头自注意力机制（Multi-head Self Attention, MSA）及其变体窗口自注意力机制（Window MSA, W-MSA）与移位窗口自注意力机制（Shifted Window MSA, SW-MSA）。
- ❑ 针对MSA全局计算导致的平方计算复杂度，Swin Transformer提出了W-MSA和SW-MSA，首先将Q、K、V划分为多个窗口，然后在每个小窗口内分别应用MSA。W-MSA与SW-MSA的区别在于窗口划分的策略不同，如下图所示。在W-MSA后添加SW-MSA旨在解决W-MSA模块缺乏跨窗口之间信息交互的问题，以进一步提高建模能力。

Transformer-Transformer类方法



(a) W -MSA窗口划分策略



(b) SW -MSA窗口划分策略

Transformer-Transformer类方法

- PureT使用Swin Transformer作为骨干编码器（Backbone Encoder）从输入图像中提取 $m=12 \times 12$ 个网格特征集合 $V_G = \{v_1, v_2, \dots, v_m\}, v_i \in \mathbb{R}^D$ ，并计算其均值池化 $v_g = (\sum_{i=1}^m v_i)/m$ 作为初始全局特征，因为Swin Transformer同为基于Transformer的模型，可以很方便地与后续增强编码器（Refining Encoder）和解码器（Decoder）联合进行端到端训练。

Transformer-Transformer类方法

□ 增强编码器（Refining Encoder）由N层相同的子模块堆叠组成，每个子模块与Transformer模型中的自注意力模块相似，但注意力机制的实现根据所处理的特征情况存在不同，MSA用于图像全局特征，SW-MSA和W-MSA则交替用于图像网格特征，表示如下：

$$\hat{V}_G^l = \text{LayerNorm}\left(V_G^{l-1} + (S)W\text{-MSA}\left(W_Q^l V_G^{l-1}, W_K^l [V_G^{l-1}; v_g^{l-1}]_s, W_V^l [V_G^{l-1}; v_g^{l-1}]_s\right)\right)$$

$$\hat{v}_g^l = \text{LayerNorm}\left(v_g^{l-1} + \text{MSA}\left(W_Q^l v_g^{l-1}, W_K^l [V_G^{l-1}; v_g^{l-1}]_s, W_V^l [V_G^{l-1}; v_g^{l-1}]_s\right)\right)$$

$$V_G^l = \text{LayerNorm}\left(\hat{V}_G^l + \text{FeedForward}(\hat{V}_G^l)\right)$$


$$v_g^l = \text{LayerNorm}\left(\hat{v}_g^l + \text{FeedForward}(\hat{v}_g^l)\right)$$

Transformer-Transformer类方法

- 其中, $W_Q^l, W_K^l, W_V^l \in \mathbb{R}^{D \times D}$ 为可学习参数, V_G^l 和 v_g^l 分别表示第 l 层子模块的输出且 $V_G^0 = V_G, v_g^0 = v_g, [V_G^{l-1}; v_g^{l-1}]_s \in \mathbb{R}^{(m+1) \times D}$ 表示网格特征与全局特征的堆叠操作, 即在应用注意力机制时, PureT同时使用了网格特征和全局特征而非单独进行处理。
- 需要指出的是, 网格特征和全局特征的增强过程所使用的参数是共享的。

Transformer-Transformer类方法

- ❑ 解码器 (Decoder) 同样由N层堆叠的子模块组成, 旨在以特征增强编码器得到的增强全局特征 v_g^N 和网格特征 V_G^N 作为输入逐词生成图像描述。
- ❑ 此外, 考虑到标准Transformer中多模态信息 (视觉模态与语言模态) 之间仅在交叉自注意力模块 (Cross MSA Module) 中进行交互, PureT提出了一个预融合模块 (Pre-Fusion Module) 用于将增强后的全局特征 v_g^N 融合到每个解码器子模块的输入中, 增加多模态信息之间的交互。




Transformer-Transformer类方法

- ❑ 解码器中每个子模块由四部分组成：预融合模块、语言掩码自注意力模块、交叉自注意力模块和单词生成模块。
- ❑ 预融合模块实现视觉模态与语言模态间的第一次信息交互，表示如下：

$$\mathbf{X}_{1:t-1}^{p,l} = \text{LayerNorm} \left(\mathbf{X}_{1:t-1}^{l-1} + \text{ReLU}(\mathbf{W}_f [\mathbf{X}_{1:t-1}^{l-1}; \mathbf{v}_g^N]) \right)$$

- 其中， $\mathbf{W}_f \in \mathbb{R}^{D \times 2D}$ 为线性层的可学习参数， $\mathbf{X}_{1:t-1}^{l-1} \in \mathbb{R}^{(t-1) \times D}$ 表示解码器第 $(l-1)$ 个子模块的输出， $[\mathbf{X}_{1:t-1}^{l-1}; \mathbf{v}_g^N] \in \mathbb{R}^{(t-1) \times 2D}$ 表示特征向量的拼接（Concatenation）操作， $\mathbf{X}_{1:t-1}^{p,l} \in \mathbb{R}^{(t-1) \times D}$ 作为后续语言掩码自注意力模块的输入。



Transformer-Transformer类方法

□ 语言掩码自注意力模块旨在对语言模态内（单词-单词）信息交互进行建模，表示如下：

$$\tilde{X}_{t-1}^l = \text{LayerNorm}\left(X_{t-1}^{p,l} + \text{MSA}(W_Q^{m,l} X_{t-1}^{p,l}, W_K^{m,l} X_{1:t-1}^{p,l}, W_V^{m,l} X_{1:t-1}^{p,l})\right)$$

—其中， $W_Q^{m,l}, W_K^{m,l}, W_V^{m,l} \in \mathbb{R}^{D \times D}$ 为可学习参数， $X_{t-1}^{p,l}$ 为 $(t-1)$ 时间步产生单词的词嵌入向量。

□ 交叉自注意力模块旨在对 $\tilde{X}_{1:t-1}^l$ 和 V_G^N 的模态间（单词-视觉特征）信息交互进行建模，即视觉模态与语言模态间的第二次信息交互，表示如下：

$$\hat{X}_{t-1}^l = \text{LayerNorm}\left(\tilde{X}_{t-1}^l + \text{MSA}(W_Q^{c,l} \tilde{X}_{t-1}^l, W_K^{c,l} V_G^N, W_V^{c,l} V_G^N)\right)$$

$$X_{t-1}^l = \text{LayerNorm}\left(\hat{X}_{t-1}^l + \text{FeedForward}(\hat{X}_{t-1}^l)\right)$$

谢谢！



计算机科学与技术学院

SCHOOL OF COMPUTER SCIENCE AND TECHNOLOGY