



中国科学院大学
University of Chinese Academy of Sciences

Deep Learning

Generative Adversarial Networks

Xinfeng Zhang (张新峰)

School of Computer Science and Technology

University of Chinese Academy of Sciences

Email: xfzhang@ucas.ac.cn



计算机科学与技术学院

SCHOOL OF COMPUTER SCIENCE AND TECHNOLOGY



提纲

- GAN的基本原理
- GAN限定条件优化
- GAN迭代式生成优化
- GAN结构优化
- GAN的主要应用
- 中英文术语对照

GAN产生背景

□ 机器学习方法

– 生成方法，所学习到模型称为生成式模型

- 生成方法通过观测数据学习样本与标签的联合概率分布 $P(X, Y)$ ，训练好的模型，即生成模型，能够生成符合样本分布的新数据
- 生成式模型在无监督深度学习方面占据主要位置，可以用于在没有目标类标签信息的情况下捕捉观测到或可见数据的高阶相关性

– 判别方法，所学到的模型称为判别式模型

- 判别方法由数据直接学习决策函数 $f(X)$ 或者条件概率分布 $P(Y|X)$ 作为预测的模型，即判别模型
- 判别模型经常用在有监督学习方面
- 判别方法关心的是对给定的输入 X ，应该预测什么样的输出 Y



GAN产生背景

□ 困难和前景

- 有监督学习经常比无监督学习获得更好的模型，但是有监督学习需要大量的标注数据，从长远看无监督学习更有发展前景
- 支持无监督学习的生成式模型遇到两大困难
 - 首先是人们需要大量的先验知识去对真实世界进行建模，而建模的好坏直接影响着我们的生成模型的表现
 - 真实世界的数据往往很复杂，人们要用来拟合模型的计算量往往非常庞大，甚至难以承受



生成对抗网络的提出

□ 2014年，生成对抗网络（Generative Adversarial Networks, GAN）由当时还在蒙特利尔读博士的**Ian Goodfellow**（导师Bengio）提出

- 2016年，GAN热潮席卷AI领域顶级会议，从ICLR到NIPS，大量高质量论文被发表和探讨
- 2017年入选**MIT评论35岁以下创新人物**





1

GAN的基本原理

零和博弈

□ GAN起源于博弈论中的二人零和博弈（获胜1，失败-1）

- 零和博弈（Zero-sum Game），也称零和游戏或者零和竞争。
- 在零和博弈中，参与双方的收益是完全相反的，一方的收益必然导致另一方的损失，总收益为零。
- 换句话说，参与双方的收益是互相对立的，一方的成功意味着另一方的失败。



零和博弈

- 如右图所示，以一个熟悉的石头、剪刀、布游戏为例，对零和博弈进行解析。
- 在两个人的石头剪刀布游戏中，每次博弈的结果必然是一个人赢，一个人输，或者平局。
- 设定赢者得分计1分，输者得分计-1分，平局的情况下二者得分均计0分。

			
	0, 0	1, -1	-1, 1
	-1, 1	0, 0	1, -1
	1, -1	-1, 1	0, 0

石头剪刀布游戏中的收益矩阵

零和博弈


- 假设二者进行了多轮博弈，其中甲方选手获胜的次数为N次，输掉的次数为M次，平局次数为P次。
- 这种情况下，乙方选手输掉的次数必然是N次，获胜的次数为M次，平局次数为P次。
- 如此以来，经过多轮博弈之后，甲方选手的总得分为 $1 \times N + (-1) \times M + 0 \times P$ ，乙方选手的总得分为 $1 \times M + (-1) \times N + 0 \times P$ ，那么二者得分的总和为 $1 \times N + (-1) \times M + 0 \times P + 1 \times M + (-1) \times N + 0 \times P = 0$ ，这就是零和博弈。



GAN基本原理

□ 例如：

- 由两个互为敌手的模型组成
 - 生成模型（假币制造者团队）
 - 判别模型（警察团队）
- 竞争使得两个团队不断改进他们的方法直到无法区分假币与真币



Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron C. Courville, Yoshua Bengio.
Generative Adversarial Nets. NIPS 2014: 2672-2680



评价



“我们一直在错过一个关键因素就是**无监督/预测学习**，这是指：机器给真实环境**建模、预测**可能的未来、并通过观察和演示来**理解世界是如何运行**的能力”

“GAN为创建无监督学习提供了强有力的算法框架，有望帮助我们为**AI加入常识**，我们认为，沿着这条路走下去，有不小的成功的机会能开发出更智慧的AI”

Yann LeCun

(Facebook AI Research)




GAN的发展

□ The GAN Zoo

- <https://github.com/hindupuravinash/the-gan-zoo>
- ABC-GAN, AC-GAN, ...
- BAGAN, BCGAN...
- C-GAN, CA-GAN,...
- ... α -GAN, β -GAN,...

Check out Deep Hunt - my weekly AI newsletter for this repo as blogpost and follow me on Twitter.

- 3D-ED-GAN - Shape Inpainting using 3D Generative Adversarial Network and Recurrent Convolutional Networks
- 3D-GAN - Learning a Probabilistic Latent Space of Object Shapes via 3D Generative-Adversarial Modeling (github)
- 3D-IWGAN - Improved Adversarial Systems for 3D Object Generation and Reconstruction (github)
- 3D-PhysNet - 3D-PhysNet: Learning the Intuitive Physics of Non-Rigid Object Deformations
- 3D-RecGAN - 3D Object Reconstruction from a Single Depth View with Adversarial Learning (github)
- ABC-GAN - ABC-GAN: Adaptive Blur and Control for improved training stability of Generative Adversarial Networks (github)
- ABC-GAN - GANs for LIFE: Generative Adversarial Networks for Likelihood Free Inference
- AC-GAN - Conditional Image Synthesis With Auxiliary Classifier GANs
- acGAN - Face Aging With Conditional Generative Adversarial Networks
- ACGAN - Coverless Information Hiding Based on Generative adversarial networks
- acGAN - On-line Adaptive Curriculum Learning for GANs
- ACtuAL - ACtuAL: Actor-Critic Under Adversarial Learning
- AdaGAN - AdaGAN: Boosting Generative Models
- Adaptive GAN - Customizing an Adversarial Example Generator with Class-Conditional GANs
- AdvEntuRe - AdvEntuRe: Adversarial Training for Textual Entailment with Knowledge-Guided Examples
- AdvGAN - Generating adversarial examples with adversarial networks
- AE-GAN - AE-GAN: adversarial eliminating with GAN
- AE-OT - Latent Space Optimal Transport for Generative Models
- AEGAN - Learning Inverse Mapping by Autoencoder based Generative Adversarial Nets
- AF-DCGAN - AF-DCGAN: Amplitude Feature Deep Convolutional GAN for Fingerprint Construction in Indoor Localization System
- AFGAN - Amortised MAP Inference for Image Super-resolution
- AIM - Generating Informative and Diverse Conversational Responses via Adversarial Information Maximization
- AL-CGAN - Learning to Generate Images of Outdoor Scenes from Attributes and Semantic Layouts



GAN的发展

□ NIPS 2016 Tutorial: Generative Adversarial Networks


- Author: Ian Goodfellow
- Paper: <https://arxiv.org/abs/1701.00160>
- Video: <https://channel9.msdn.com/Events/Neural-Information-Processing-Systems-Conference/Neural-Information-Processing-Systems-Conference-NIPS-2016/Generative-Adversarial-Networks>



GAN模型

□ GAN主要由两部分组成：生成器（Generator）和判别器（Discriminator），它们分别扮演了两个不同的角色。

- 生成器的任务是生成接近真实数据分布的样本，而判别器的任务则是尽可能地区分真实的样本和生成器生成的样本。
- 通过生成器和判别器之间的对抗，GAN可以学习到生成高质量样本的能力。



GAN模型

□ 生成模型


- 捕捉样本数据的分布，用服从某一分布（均匀分布，高斯分布）的噪声 z 生成一个类似真实训练数据的样本，追求效果是越像真实的数据越好
- $p_{data}(x)$ 表示真实数据的 x 分布
- $p_z(z)$ 表示输入噪声变量 z 的分布
- p_g 表示在数据 x 上学习得到的生成样本的分布
- $G(z; \theta_g)$ 表示生成模型（多层感知器）



GAN模型

□ 生成模型(示例)


- 可以看做一种映射函数
- 当数据集是图片的时候，那么我们输入的随机噪声其实就是相当于低维的数据，经过生成模型G的映射就变成了一张生成的图片 $G(x, \theta_g)$



GAN模型

□ 生成模型(示例)

- 可以看做一种映射函数
- 当数据集是图片的时候，那么我们输入的随机噪声其实就是相当于低维的数据，经过生成模型G的映射就变成了一张生成的图片 $G(x, \theta_g)$



GAN模型


□ 判别模型

- 一个二分类器，估计一个样本来自训练数据（而非生成数据）的概率，如果样本来自真实的训练数据，输出大概率，否则，输出小概率。
- $D(x; \theta_d)$ 表示判别模型（多层感知器）
- $D(x)$ 表示 x 来自真实数据而非生成数据的概率



GAN模型

□ 用网络代替概率模型 $P_g(x; \theta)$, $P_{data}(x)$



GAN的基本结构

□ 以图片生成为例进行说明

- 生成器是一个生成图片的网络，它使用服从某一分布（均匀分布或高斯分布）的噪声生成一个类似真实训练数据的图片，记作 $G(z)$ ，追求效果是越像真实图片越好。
- 判别器是一个二分类器，用来判断一个图片是不是“真实的”，它的输入是采样的真实图片 x 以及生成器生成的图片 $G(z)$ ，输出是输入图片是真实图片的概率，如果输入图片来自真实数据，那么判别器输出大的概率，否则，输出小的概率。



GAN 目标函数

- GAN的目标是使生成器生成的数据能够骗过判别器，因此需要定义一个目标函数，使得生成器判断真实样本为“真”、生成样本为“假”的概率最小化。

$$\min_G \max_D V(G, D) = E_{x \sim p_{data}(x)} [\log D(x)] + E_{z \sim p_z(z)} [\log (1 - D(G(z)))]$$

- 训练GAN的时候，**判别模型希望目标函数最大化**，也就是使判别模型判断真实样本为“真”，判断生成样本为“假”的概率最大化，要尽量**最大化自己的判别准确率**
- 判别模型也可以写成损失函数的形式

$$L(G, D) = - E_{x \sim p_{data}(x)} [\log D(x)] - E_{z \sim p_z(z)} [\log (1 - D(G(z)))]$$



GAN损失函数

□ 与判别器相反，生成模型希望该目标函数最小化，也就是降低判别模型对数据来源判断正确的概率，要最小化判别模型的判别准确率

□ 生成模型训练目标

$$V(G, D) = \overline{E_{x \sim p_{data}(x)} [\log D(x)]} + E_{z \sim p_z(z)} [\log (1 - D(G(z)))]$$

– 实际中效果并不好，开始时梯度小收敛慢，因此使用如下目标


$$V = E_{z \sim p_z(z)} [-\log (D(G(z)))]$$



GAN损失函数

$$V = E_{x \sim p_g(x)} [-\log(D(x))]$$

$$V = E_{x \sim p_g(x)} [\log(1 - D(x))]$$



GAN模型训练

- GAN在训练的过程中固定一方，更新另一方的网络权重
- 交替迭代，在这个过程中，双方都极力优化自己的网络，从而形成竞争对抗，直到双方达到一个动态的平衡（纳什均衡）
- 此时生成模型的数据分布无限接近训练数据的分布（造出了和真实数据一模一样的样本），判别模型再也判别不出来真实数据和生成数据，准确率为 50%




GAN模型训练

□ GAN的训练过程包含三个步骤：

- 首先使用采样的真实数据 x 训练判别器，即输入真实数据 x 到判别器，前向传播，得到输出为1（表示判断结果为真），之后使用反向传播算法更新判别器的参数。
- 使用生成器生成的数据 $G(z)$ 训练判别器，即输入生成器生成的数据 $G(z)$ 到判别器，前向传播，得到输出为0（表示判断结果为假），之后使用反向传播算法再次更新判别器的参数。
- 使用生成器生成的数据 $G(z)$ 训练生成器，即输入生成器生成的数据 $G(z)$ 到判别器，采用上一步训练好的判别器的参数（冻结判别器的参数）前向传播，得到输出为1（表示判断结果为真），之后使用反向传播算法更新生成器的参数，这一步的目的在于训练更好的生成器，以迷惑判别器，使之将生成器生成的数据判别为真。



GAN模型训练



GAN模型训练

Algorithm 1 Minibatch stochastic gradient descent training of generative adversarial nets. The number of steps to apply to the discriminator, k , is a hyperparameter. We used $k = 1$, the least expensive option, in our experiments.

for number of training iterations **do**

for k steps **do**

- Sample minibatch of m noise samples $\{z^{(1)}, \dots, z^{(m)}\}$ from noise prior $p_g(z)$.
- Sample minibatch of m examples $\{x^{(1)}, \dots, x^{(m)}\}$ from data generating distribution $p_{\text{data}}(x)$.
- Update the discriminator by ascending its stochastic gradient:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m \left[\log D(x^{(i)}) + \log (1 - D(G(z^{(i)}))) \right].$$

$$\theta_d \leftarrow \theta_d + \eta \nabla \tilde{V}(\theta_d)$$

end for

- Sample minibatch of m noise samples $\{z^{(1)}, \dots, z^{(m)}\}$ from noise prior $p_g(z)$.
- Update the generator by descending its stochastic gradient:

$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^m \log (1 - D(G(z^{(i)})))$$

$$\theta_g \leftarrow \theta_g - \eta \nabla \tilde{V}(\theta_g)$$

end for

The gradient-based updates can use any standard gradient-based learning rule. We used momentum in our experiments.

Learning
D

Repeat
k times

Learning
G

Only
Once



优势和不足

□ 优势

- 任何一个可微分函数都可以参数化D和G（如深度神经网络）。
- 支持无监督方法实现数据生成，减少了数据标注工作
- 生成模型G的参数更新不是来自于数据样本本身（不是对数据的似然性进行优化），而是来自于判别模型D的一个反传梯度



优势和不足

□ 不足

- 无需预先建模，数据生成的自由度太大
- 得到的是概率分布，但是没有表达式，可解释性差
- D与G训练无法同步，训练难度大，会产生梯度消失问题





2

GAN限定条件优化

限定条件优化

- 通过加入一些限定条件，可以让生成器产生更多样、更有价值的图像。例如，如果希望GAN生成属于特定类别的图像，可以在训练GAN时加入额外的标签信息。
- 如一个手写数字图像的分类标签，并将这些标签输入生成器，那么生成器的目标就不仅仅是产生逼真的图像，还应该去满足类别这一约束条件，其他约束也类似。



GAN的优化和改进

□ 限定条件优化

- CGAN: Conditional Generative Adversarial Nets
- InfoGAN: Interpretable Representation Learning by Information Maximizing Generative Adversarial Nets
- Improved Techniques for Training GANs
- GP-GAN: Towards Realistic High-Resolution Image Blending
- Pix2Pix: Image-to-Image Translation with Conditional Adversarial Networks




CGAN

- CGAN的中心思想是可以控制GAN生成样本，减少随机性。
- 在CGAN中，生成器G接受一个噪声向量 z 和一个条件 y （通常是一个标签）为输入，它的任务是生成一个具有特定条件的图像，它的表现会在与判别器D的对抗中被衡量。
- D的任务是给定一个图像，判断它是真实的（来自真实数据集）或者是虚假的（由G生成的）。



CGAN



- 在生成模型中, 先验输入噪声 $p(z)$ 和条件信息 y 联合组成了联合隐层表征
- y 是一些附加信息, 可以是 one-hot 向量, 也可以是图像或者分类标签
- 条件 GAN 的目标函数是带有条件概率的 **二人极小极大值博弈** (two-player minimax game)



CGAN

□ CGAN的目标函数如下：

$$\min_G \max_D V(D, G) = E_{x \sim p_{data}(x)} [\log D(x|y)] + E_{z \sim p_z(z)} [\log (1 - D(G(z|y)))]$$

- $E_{x \sim p_{data}(x)} [\log D(x|y)]$ 表示在给定条件 y 的情况下当样本采样自真实数据集的时候判别器能够准确判别其为真的期望，
- $E_{z \sim p_z(z)} [\log (1 - D(G(z|y)))]$ 表示在给定条件 y 和输入噪声 z 的情况下通过生成器生成的样本数据被判别器判别为假的期望。



CGAN

□ CGAN性能




Generated MNIST digits, each row conditioned on one label


Text to Image Synthesis

□ Text to image

— 传统有监督训练方法





Text: “train”





Scott Reed, Zeynep Akata, Xincheng Yan, Lajanugen Logeswaran, Bernt Schiele, Honglak Lee, “Generative Adversarial Text-to-Image Synthesis”, ICML 2016

Text to Image Synthesis



Text to Image Synthesis



Text to Image Synthesis

- In each training iteration
 - Sample m positive examples $\{(c^1, x^1), (c^2, x^2), \dots, (c^m, x^m)\}$ from database
 - Sample m noise examples $\{z^1, z^2, \dots, z^m\}$ from a distribution
 - Obtaining generated data $\{\tilde{x}^1, \tilde{x}^2, \dots, \tilde{x}^m\}$ from $\hat{x}^i = G(c^i, z^i)$
 - Sample m objects $\{\hat{x}^1, \hat{x}^2, \dots, \hat{x}^m\}$ from database
 - Update discriminator parameters to θ_d maximize
 - $$V = \frac{1}{m} \sum_{i=1}^m \log D(c^i, x^i) + \frac{1}{m} \sum_{i=1}^m \log (1 - D(c^i, \tilde{x}^i)) + \frac{1}{m} \sum_{i=1}^m \log (1 - D(c^i, \hat{x}^i))$$
 - $\theta_d = \theta_d + \lambda \nabla V(\theta_d)$
 - Sample m noise examples $\{z^1, z^2, \dots, z^m\}$ from a distribution
 - Sample m conditions $\{c^1, c^2, \dots, c^m\}$ from a database
 - Update generator parameters θ_g to minimize
 - $$V = \frac{1}{m} \sum_{i=1}^m \log (1 - D(G(c^i, z^i))), \quad \theta_g = \theta_g - \lambda \nabla V(\theta_g)$$



InfoGAN

□ 解决的问题

- 输入随机向量，GAN生成模型缺乏解释性
- 例如：修改输入向量某个维度生成图像变化可能没有规律，可能是随机的
- InfoGAN：希望能够让输入向量的不同维度代表不同的特征，具有可解释性



□ 基本原理

- 利用 z 寻找一个可解释的表达, 将 z 进行拆解
 - 不可压缩的噪声 z'
 - 可解释的隐变量 c , 称为latent code
- 通过约束 c 与生成数据的关系, 使得 c 里面可以包含某些语义特征
 - 比如MNIST实验的 c 就可以由一个取值范围为0-9的离散随机变量 (用于表示数字) 和两个连续的随机变量 (分别用于表示倾斜度和粗细度) 构成



InfoGAN

□ InfoGAN主要由以下4个部分组成：

- 输入部分：与CGAN相同，InfoGAN的输入包括一个随机噪声变量 z 和一个条件变量 c ，其中条件变量称为“已知变量”。
- 生成器：生成器的作用是将输入的随机噪声变量 z 和条件变量 c 转换成一张图像，并尽可能使生成的图像与真实图像相似。具体来说，生成器会将输入的两种变量转换成一种不连续的变量 x ，这意味着生成器输出的图像会因为各种条件变量的变化而产生明显的变化。




□ InfoGAN主要由以下4个部分组成：

- 判别器：判别器的作用是判断输入的图像是真实的还是生成的。在InfoGAN中，判别器除了输出一个二进制的真假结果外，还会输出一个表示判决结果可信度的概率值。
- 分类器：在InfoGAN中，还配备了一个用于学习特征提取的分类器。这个分类器会从生成器的输出中提取特征，并将特征分解为可解释的约束 c 。这个过程就是InfoGAN提供的“信息推断”部分，用于学习数据分布中的隐含因素并将其分解成为独立的特征。



InfoGAN



- 通过增加正则约束实现

$$\min_G \max_D V_I(D, G) = V(D, G) - \lambda I(c; G(z, c))$$

互信息: $I(X; Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$



InfoGAN

- ❑ 与原始GAN相比，该目标函数增加了一项 $\lambda I(c; G(z, c))$ ，这一项代表的是 c 与生成器的输出 $G(z, c)$ 之间的互信息。这一项越大，表示 c 与 $G(z, c)$ 越相关。
- ❑ 在训练过程中，InfoGAN在生成数据的同时，学习如何去操纵潜在空间中的特定因素，以生成特定的图像或数据，直观的理解就是，如果 c 的每一个维度对输出都有明确的影响，那么分类器就可以根据 x 返回原来的 c 。如果 c 对输出没有明显的影响，那么分类器也无法返回原来的 c 。



InfoGAN


□ 实验结果

- 从左到右变化 c_1, c_2, c_3 : c_1 控制数字类型, c_2 控制向右倾斜, c_3 控制字体粗细



(a) Varying c_1 on InfoGAN (Digit type)

(b) Varying c_1 on regular GAN (No clear meaning)



(c) Varying c_2 from -2 to 2 on InfoGAN (Rotation)

(d) Varying c_3 from -2 to 2 on InfoGAN (Width)



InfoGAN

□ 实验结果

— 控制人脸的生成



(a) Azimuth (pose)

(b) Elevation



(c) Lighting

(d) Wide or Narrow





3

GAN迭代式生成优化

迭代式生成优化

- 迭代生成优化方法通过在生成器中引入一种可迭代的机制，对生成的样本进行逐步的精炼和改进，这个机制可以在训练过程中不断更新生成器的参数，以生成更高质量和多样化的样本。
- 代表性的迭代式生成优化工作主要有LAPGAN和StackGAN。



迭代式生成优化

- ❑ **LAPGAN: Deep Generative Image Models using a Laplacian Pyramid of Adversarial Networks**
- ❑ **StackGAN: Text to Photo-realistic Image Synthesis with Stacked Generative Adversarial Networks**
- ❑ **PPGN: “Plug & Play Generative Networks: Conditional Iterative Generation of Images in Latent Space**



□ 解决的问题

— 高分辨率图像生成

- 在原始 GAN和CGAN中，还只能生成 $16*16$, $28*28$, $32*32$ 这种小尺寸的图片
- 而LAPGAN首次实现 $64*64$ 的图像生成。采用由coarse-to-fine的渐进生成方式，每一步生成的时候，可以基于上一步的结果，只需要“填充”和“补全”新图片所需要的那些信息
- LAPGAN通过级联方式改进GAN以实现从粗略到精细图片的生成。网络的级联思想对后续的研究产生了极大的影响。LAPGAN使用高斯金字塔进行下采样，使用拉普拉斯金字塔进行上采样。



LAPGAN

□ 生成的结构框图

- 输入噪声 z_3 , 经 G_3 生成 $\tilde{I}_3$, 上采样得到 l_2 , 使用 l_2 作为条件输入 G_2 生成差分图像 $\tilde{h}_2$, 添加到 l_2 中生成 $\tilde{I}_2$





Figure 1: The sampling procedure for our LAPGAN model. We start with a noise sample z_3 (right side) and use a generative model G_3 to generate $\tilde{I}_3$. This is upsampled (green arrow) and then used as the conditioning variable (orange arrow) l_2 for the generative model at the next level, G_2 . Together with another noise sample z_2 , G_2 generates a difference image $\tilde{h}_2$ which is added to l_2 to create $\tilde{I}_2$. This process repeats across two subsequent levels to yield a final full resolution sample $\tilde{I}_0$.

LAPGAN

□ 训练过程

- 输入 64×64 图像, $I_0 = I$, 模糊和2倍因子下采样(红线), 产生 I_1
- 2倍上采样 I_1 (绿线) 生成 I_0 的低通版本 l_0 , 用于生成真实的高频信息和低频信息



LAPGAN

□ 假设图像 I 的长度和宽度均为 h, w ，对于图像 $I_0=(h, w)$ ，下采样得到的图像尺寸为 $(h/2, w/2)$ ，上采样得到的图像尺寸为 $(2h, 2w)$ 。对于图像进行连续 k 次的下采样，可以获得一系列图像 $I_1=(h/2, w/2), I_2=(h/4, w/4), \dots, I_k=(h/2^k, w/2^k)$

$$G(I) = [I_0, I_1, \dots, I_k]$$

– 其中， $G(I)$ 表示图像的高斯金字塔。在得到高斯金字塔之后，拉普拉斯金字塔可表示如下：

$$h_k = \mathcal{L}_k(I) = G_k(I) - u(G_{k+1}(I)) = I_k - u(I_{k+1})$$

其中，拉普拉斯金字塔的第 k 层等于高斯金字塔的第 k 层 $G_k(I)$ 减去高斯金字塔第 $(k+1)$ 层的上采样 $u(G_{k+1}(I))$ 。



LAPGAN

□ LAPGAN将条件对抗生成网络CGAN集成到拉普拉斯金字塔结构中：


$$\tilde{\mathbf{I}}_k = u(\tilde{\mathbf{I}}_{k+1}) + \tilde{\mathbf{h}}_k = u(\tilde{\mathbf{I}}_{k+1}) + G_k(\mathbf{z}_k, u(\tilde{\mathbf{I}}_{k+1}))$$

- 其中， G_k 表示第 k 个卷积神经网络，也就是生成器，高斯金字塔第 k 层的重建等于它的第 $(k+1)$ 层上采样 $u(\tilde{\mathbf{I}}_{k+1})$ 加上拉普拉斯金字塔的第 k 层 $\tilde{\mathbf{h}}_k$
- 除了最高层的生成器之外，其余生成器 G_0 、 $G_1 \dots G_{k-1}$ 都是采用上一级的上采样和噪声作为联合输入。上采样的结果就是LAPGAN中的条件变量。



LAPGAN

□ Coarse-to-fine的视觉效果




□ 文本到图像生成

- 解决文本到图像生成分辨率不高的问题，采用与LAPGAN相似的思路，采用coarse-to-fine的思路，构建两个GAN
 - 第一个GAN用于根据文本描述生成一张低分辨率的图像
 - 第二个GAN将低分辨率图像和文本作为输入，修正之前生成的图像并添加细节纹理，生成高分辨率图像



StackGAN



StackGAN

- StackGAN分为两个阶段，阶段I的GAN以文本嵌入为条件信息生成具有基本颜色和粗略草图的低分辨率图像。文本描述 t 首先由一个编码器进行编码，从而生成一个文本嵌入 φ_t ，然而基于文本条件信息的潜在空间通常是高维的（大于100维），在数据量有限的情况下，通常会导致潜在数据流形的不连续，这不适合学习生成器。
- 为了缓解这一问题，引入了一种条件增强技术，为生成器产生更多的条件变量。从一个独立的高斯分布 $\mathcal{N}(\mu(\varphi_t), \Sigma(\varphi_t))$ 中随机采样潜在变量，从而在少量的图像-文本对情况下产生更多的训练对。为了进一步加强条件流形的平滑性，避免过拟合，在训练过程中对生成器的目标添加了如下正则化项。

$$D_{KL}(\mathcal{N}(\mu(\varphi_t), \Sigma(\varphi_t)) || \mathcal{N}(0, I))$$



□ 这是标准高斯分布和条件高斯分布之间的Kullback-Leibler散度（KL散度）。在 Gaussian 潜在变量 c_0 的条件下，第一阶段GAN通过在下述公式中最大化 L_{D_0} 来训练判别器，用最小化 L_{G_0} 来训练生成器，如下所示：

$$L_{D_0} = E_{(I_0, t) \sim p_{data}} [\log D_0(I_0, \varphi_t)] + E_{z \sim p_z, t \sim p_{data}} [\log(1 - D_0(G_0(z, \hat{c}_0), \varphi_t))]$$

$$L_{G_0} = E_{z \sim p_z, t \sim p_{data}} [\log(1 - D_0(G_0(z, \hat{c}_0), \varphi_t))] + \lambda D_{KL}(\mathcal{N}(\mu_0(\varphi_t), \Sigma_0(\varphi_t)) || \mathcal{N}(0, I))$$

其中，真实的图像 I_0 和文本描述 t 来自真实的数据分布 p_{data} ， z 是一个从一个给定的分布 p_z 中随机采样的噪声向量， λ 是一个正则化参数，它控制了两项之间的平衡。 φ_t 是由一个预先训练好的编码器生成的文本嵌入。



- 由阶段I的GAN生成的低分辨率图像缺乏生动的对象部分，也可能包含形状失真。此外，文本中的一些细节在第一阶段可能会被省略。而这是生成真实图像所需的重要信息。
- 阶段II的GAN获取由阶段I的GAN生成的图像，并以文本嵌入为条件信息生成高分辨率图像。这一阶段的模型主要用来进行缺陷纠正和细节添加，产生逼真的高分辨率图像。基于低分辨率样本 s_0 和高斯潜在向量 $\hat{c}$ ，这一阶段GAN中的判别器D和生成器G的损失函数如下所示：

$$L_D = E_{(I,t) \sim p_{data}} [\log D(I, \boldsymbol{\varphi}_t)] + E_{s_0 \sim p_{G_0}, t \sim p_{data}} [\log(1 - D(G(s_0, \hat{c}), \boldsymbol{\varphi}_t))]$$

$$L_G = E_{s_0 \sim p_{G_0}, t \sim p_{data}} [\log(1 - D(G(s_0, \hat{c}), \boldsymbol{\varphi}_t))] + \lambda D_{KL}(\mathcal{N}(\mu(\boldsymbol{\varphi}_t), \Sigma(\boldsymbol{\varphi}_t)) || \mathcal{N}(0, I))$$



StackGAN

- 其中 $s_0 = G_0(z, c_0)$ ，由阶段I的GAN生成。与原始GAN公式不同，随机噪声 z 在这个阶段并没有被使用。本阶段使用的高斯条件向量 $\hat{c}$ 和阶段I的GAN中使用的 $\hat{c}_0$ 共享相同的预先训练好的文本编码器生成的文本嵌入 φ_t 。但是，它们利用不同的全连接层来产生不同的均值和标准差。



StackGAN

Text description	This bird is red and brown in color, with a stubby beak	The bird is short and stubby with yellow on its body	A bird with a medium orange bill white body gray wings and webbed feet	This small black bird has a short, slightly curved bill and long legs	A small bird with varying shades of brown with white under the eyes	A small yellow bird with a black crown and a short black pointed beak	This small bird has a white breast, light grey head, and black wings and tail
64x64 GAN-INT-CLS							
128x128 GAWWN							
256x256 StackGAN							



4

GAN结构优化



结构优化

- ❑ DCGAN: Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks
- ❑ Pix2Pix: Image-to-Image Translation with Conditional Adversarial Networks
- ❑ PPGN: “Plug & Play Generative Networks: Conditional Iterative Generation of Images in Latent Space





DCGAN

- ❑ DCGAN将CNN和GAN结合在一起，将CNN作为GAN中的生成器和判别器。
- ❑ 需要注意的是，DCGAN并非在生成器和判别器中使用通用的CNN，而是对CNN进行了部分修改：
 - 首先，取消了CNN中的所有池化层，在生成器中使用反卷积进行上采样，在判别器中使用加入步长（Stride）的卷积代替池化层；
 - 其次，除了生成器的输出层和判别器的输入层，在网络的其它层上都进行了批归一化；
 - 再次，移除完全连接的隐藏层，以实现更深层次的体系结构；
 - 最后，在生成器中，除了输出层使用Tanh激活函数之外，其它层使用ReLU激活函数，判别器的所有层均使用LeakyReLU激活函数。



DCGAN

- 所有的pooling层使用Strided convolution (步幅卷积, 判别网络)和Fractional-strided convolutions (分散步幅卷积, 生成网络)进行替换。



DCGAN




Figure 1: DCGAN generator used for LSUN scene modeling. A 100 dimensional uniform distribution Z is projected to a small spatial extent convolutional representation with many feature maps. A series of four fractionally-strided convolutions (in some recent papers, these are wrongly called deconvolutions) then convert this high level representation into a 64×64 pixel image. Notably, no fully connected or pooling layers are used.




DCGAN




Pix2Pix

- Pix2Pix面向图像翻译任务，是基于前面讲述的CGAN进行优化而实现的。Pix2Pix在图像翻译中将输入图像作为条件，学习从输入图像到输出图像之间的映射，从而得到指定的输出图像。



Pix2Pix

□ x 是输入的边缘图， y 是真实图像， G 为生成器， $G(x)$ 是生成的图像， D 为判别器。生成器学习如何欺骗判别器以生成更逼真的图像，判别器学习如何判别出哪些是真实图像哪些是生成的假图像。和非条件GAN不同的是，条件GAN的生成器和判别器都可以观察到输入的边缘图。



Pix2Pix

- Pix2Pix从三个方面对CGAN进行了优化，包括目标函数、生成器的网络结构和判别器的判别方式。首先，Pix2Pix的损失函数定义如下：

$$\min_G \max_D V(D, G) = E_{x,y}[\log D(x, y)] + E_{x,z}[\log(1 - D(x, G(x, z)))] + \lambda L_{L1}(G)$$
$$L_{L1}(G) = E_{x,y,z}[||y - G(x, z)||]$$

- Pix2Pix的损失函数中增加了L1约束项，使生成图像不仅要接近真实图像，也要接近输入的条件图像；其次，在Pix2Pix的生成器中使用了Unet结构，通过在网络中直接传递和共享底层信息提升了GAN的性能；最后，Pix2Pix的判别器使用分块判断算法PatchGAN。
- 原始GAN在评价输入图像时，输出“真”或“假”的二分类结果，与原始GAN不同，PatchGAN的输出是一个N×N的矩阵，其中每一个元素表示来自原图中的一个感受野。



Pix2Pix

- Pix2Pix的实验结果表明，CGAN是适用于图像到图像翻译任务的一种很有前景的方法，尤其是那些涉及高度结构化的图像输出任务。从应用角度来看，Pix2Pix在标签转图像、黑白图像转彩色图像、边缘图转为图像等任务中表现突出，Pix2Pix也可以在更多涉及到图像翻译的实际应用中发挥作用。



Pix2Pix




Figure 1: Many problems in image processing, graphics, and vision involve translating an input image into a corresponding output image. These problems are often treated with application-specific algorithms, even though the setting is always the same: map pixels to pixels. Conditional adversarial nets are a general-purpose solution that appears to work well on a wide variety of these problems. Here we show results of the method on several. In each case we use the same architecture and objective, and simply train on different data.

谢谢！



计算机科学与技术学院

SCHOOL OF COMPUTER SCIENCE AND TECHNOLOGY