



中国科学院大学
University of Chinese Academy of Sciences

Deep Learning

Generative Adversarial Networks

Xinfeng Zhang (张新峰)

School of Computer Science and Technology

University of Chinese Academy of Sciences

Email: xfzhang@ucas.ac.cn



计算机科学与技术学院

SCHOOL OF COMPUTER SCIENCE AND TECHNOLOGY



提纲

- GAN的基本原理
- GAN限定条件优化
- GAN迭代式生成优化
- GAN结构优化
- GAN的主要应用
- 中英文术语对照




5

GAN的主要应用

图像生成

□ GAN在图像生成（Image Generation）中的主要方法分为直接方法、迭代方法和分层方法三种。




图像生成

- 所有属于直接方法的GAN图像生成方法都采用一个生成器和一个判别器的结构，许多早期的GAN都属于这一类，如GAN、InfoGAN和DCGAN等，其中DCGAN是最典型的图像生成模型之一，其结构被后来的许多模型使用
- 分层方法使用了两个生成器和两个判别器，这类方法的核心思想是将图像分成两个部分：“样式和结构”和“前景和背景”，两个生成器的关系可以是并行或者串行的关系。分层方法的代表性工作是SS-GAN，它包含两个部分：结构GAN（Structure-GAN）生成一个表面法线图，风格GAN（Style-GAN）以表面法线图为输入，生成二维图像。两个GAN首先独立训练，然后通过联合学习融合在一起。



图像生成

- SS-GAN, 它包含两个部分：结构GAN (Structure-GAN) 生成一个表面法线图，风格GAN (Style-GAN) 以表面法线图为输入，生成二维图像。两个GAN首先独立训练，然后通过联合学习融合在一起。



Wang, Xiaolong, and Abhinav Gupta. "Generative image modeling using style and structure adversarial networks." In *European conference on computer vision*, pp. 318-335. Cham: Springer International Publishing, 2016.



图像生成

- ❑ 迭代方法与分层方法不同，该类方法使用具有相似或者相同结构的多个生成器，这些生成器从粗略到精细进行图像生成，与分层方法不同的是相同结构的生成器可以在迭代过程中共享权重。
- ❑ LAPGAN是第一个使用拉普拉斯金字塔迭代方法从粗略到精细生成图像的GAN模型，其中多个生成器执行相同的任务，具体来说，LAPGAN中的每个生成器将前一个生成器得到的图像和噪声作为输入，输出更加清晰的结果，这些生成器的区别在于它们的输入和输出尺寸大小，LAPGAN在图像生成领域中的表现优于原始GAN。




图像转换

- ❑ 图像转换（Image Conversion）是指将一张图像转换为另一张图像，这在计算机视觉中是一个非常重要的任务。
- ❑ 前文介绍的Pix2Pix模型是GAN在图像转换领域的一个经典模型，该模型将CGAN中的损失函数与L1正则化损失函数相结合，尝试让生成器不仅仅可以欺骗判别器，并且能够尽可能地生成接近真实图像的图像。



图像转换

□ 没有对齐的图像对作为训练数据，该如何转换？



图像转换

□ CycleGAN的设计思路：如果有两个域A和B，想要将域A中的图像转换成域B中的图像，同时还想保持语义不变，那么可以训练两个生成器，分别用于将A域图像翻译成B域图像、将B域图像翻译成A域图像。




Figure 3: (a) Our model contains two mapping functions $G : X \rightarrow Y$ and $F : Y \rightarrow X$, and associated adversarial discriminators D_Y and D_X . D_Y encourages G to translate X into outputs indistinguishable from domain Y , and vice versa for D_X and F . To further regularize the mappings, we introduce two *cycle consistency losses* that capture the intuition that if we translate from one domain to the other and back again we should arrive at where we started: (b) forward cycle-consistency loss: $x \rightarrow G(x) \rightarrow F(G(x)) \approx x$, and (c) backward cycle-consistency loss: $y \rightarrow F(y) \rightarrow G(F(y)) \approx y$


Zhu, Jun-Yan, Taesung Park, Phillip Isola, and Alexei A. Efros. "Unpaired image-to-image translation using cycle-consistent adversarial networks." In *Proceedings of the IEEE international conference on computer vision*, pp. 2223-2232. 2017.



图像转换

□ CycleGAN包含两个判别器和两个生成器：

- 生成器A2B：将真实马的图片转换成相同形状的斑马图片（图的上半部分）或者将生成的假的马的图片转换成相同形状的斑马图片（图的下半部分）；
- 生成器B2A：将真实的斑马图片转换成相同形状的马的图片（图的下半部分）或者将生成的斑马图片转换成相同形状的马的图片（图的上半部分）；
- 判别器A：判断真实的马的图片或者生成的马的图片是否为真；
- 判别器B：判断真实的斑马图片或者生成的斑马图片是否为真。



图像转换

□ CycleGAN使用的损失函数是两个循环一致性损失（Cycle Consistency Loss）的和，具体表示如下：

$$L_{cyc}(G, F) = E_{x \sim p_{data}(x)} [\|F(G(x)) - x\|_1] + E_{y \sim p_{data}(y)} [\|G(F(y)) - y\|_1]$$

- 其中，G指的是生成器A2B，F指的是生成器B2A，循环一致性损失是为了防止图像迁移后形状差异较大而提出的，就是说当马的图片通过两个生成器后变回原来的马的图片，计算两个马的图片的距离，如果两者距离越小，就代表两个图片越相似。


□ 整体的目标函数：

$$\mathcal{L}(G, F, D_X, D_Y) = \mathcal{L}_{GAN}(G, D_Y, X, Y) + \mathcal{L}_{GAN}(F, D_X, Y, X) + \lambda \mathcal{L}_{cyc}(G, F)$$




图像转换

□ CycleGAN的一个重要应用是域迁移，可以将图片转换为不同风格的图片。



图像转换

- DualGAN是一种基于对偶学习的图像转换模型，与CycleGAN类似，这个模型也可以实现两个域之间的图像转换。
- DualGAN使用自编码器和GAN结合的网络架构，同时对源域和目标域进行图像转换，并且通过对偶学习方式进行优化。



Yi, Zili, Hao Zhang, Ping Tan, and Minglun Gong. "Dualgan: Unsupervised dual learning for image-to-image translation." In *Proceedings of the IEEE international conference on computer vision*, pp. 2849-2857. 2017.



图像转换

□ DualGAN为两个域（一个源域U和一个目标域V）各设计了一个生成器和一个判别器。

- 源域的生成器 G_A 将源域的图片转换到目标域中，目标域的生成器 G_B 则将目标域的图片转化到源域中。
- 源域的判别器 D_B 用于区分生成器 G_B 生成的图像和源域中的真实图像，目标域的判别器 D_A 用于区分生成器 G_A 生成的图像和目标域中的真实图像。
- 通过这些生成器和判别器的协作变换，DualGAN可以实现源域图像到目标域的全方位变换，同时也可以从目标域将图像转换回源域。



图像转换

- 示意图以素描与照片之间的相互转换为例，其中第一个生成器 G_A 可以将素描 (U) 转换为照片 (V)，生成器 G_A 所完成的任务正是最终想要完成的任务，与这个生成器对应的有一个判别器 D_A 。
- 与此同时，构建与之对偶的另一个生成器 G_B ，将照片转换为素描，与这个生成器所对应的同样有一个判别器 D_B 。



图像转换

□ 在DualGAN中，对偶学习引入了两个额外的自编码器用于计算源域图片转化到目标域图片和目标域图片转化到源域图片之间的重构误差：

$$l^g(\mathbf{u}, \mathbf{v}) = \lambda_U \|\mathbf{u} - G_B(G_A(\mathbf{u}, \mathbf{z}), \mathbf{z}')\| + \lambda_V \|\mathbf{v} - G_A(G_B(\mathbf{v}, \mathbf{z}'), \mathbf{z})\| - D_B(G_B(\mathbf{v}, \mathbf{z}')) - D_A(G_A(\mathbf{u}, \mathbf{z}))$$

- 其中 λ 为权重参数。生成器 G_A 可以对素描图片 $\mathbf{u}$ 进行转换，最终得到类似照片的图片，其中包含的噪声为 $\mathbf{z}$ ，转换的结果即为 $G_A(\mathbf{u}, \mathbf{z})$ ，把这个转换的结果送给另一个专门用于生成素描图片的生成器 G_B ，得到的结果为 $G_B(G_A(\mathbf{u}, \mathbf{z}), \mathbf{z}')$ ，即为对原有的素描图片的一次重构，这里的 $\mathbf{z}'$ 指的也是噪声。



图像转换

□ DualGAN的转换结果



Figure 8: Map→aerial photo translation. Without image correspondences for training, DualGAN may map the orange-colored interstate highways to building roofs with bright colors. Nevertheless, the DualGAN results are sharper than those from GAN and cGAN.




Figure 9: Results for aerial photo→map translation. DualGAN performs better than GAN, but not as good as cGAN. With additional pixel correspondence information, cGAN performs well in terms of labeling local roads, but still cannot detect interstate highways.

图像超分辨率重建

- 图像超分辨率重建 (Image Super-Resolution Reconstruction) 是指一种将一幅低分辨率图像重建出高分辨率图像的技术。
- 很多GAN的变种被用于图像超分辨率重建，效果很好，如SRGAN、FSRAGAN等，这里主要介绍SRGAN。





Figure 2: From left to right: bicubic interpolation, deep residual network optimized for MSE, deep residual generative adversarial network optimized for a loss more sensitive to human perception, original HR image. Corresponding PSNR and SSIM are shown in brackets. [4× upscaling]

Ledig, Christian, Lucas Theis, Ferenc Huszár, Jose Caballero, Andrew Cunningham, Alejandro Acosta, Andrew Aitken et al. "Photo-realistic single image super-resolution using a generative adversarial network." In Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 4681-4690. 2017.



图像超分辨率重建


- ❑ SRGAN的生成网络由常规的卷积层组成并引入了残差结构和像素重排来进行高分辨率图像生成。
- ❑ 生成器的网络结构由16个重复的块堆叠而成，每一个块都包含“卷积/批归一化/PreLU激活函数/卷积/批归一化/残差相加”的结构。



生成器的结构

图像超分辨率重建

- ❑ 判别器的网络结构与生成器的网络结构类似，包含8个卷积层，从第2个卷积层开始，每一个卷积层后面加一个批归一化层来归一化中间层的分布。
- ❑ 图中字符串“k3n64s1”中的k3代表卷积核的大小为3，n64代表卷积输出的通道数为64，s1代表步长为1，下面两个不同指向的箭头表示残差连接。



判别器的结构



图像超分辨率重建

□ 在SRGAN中，生成器G的输入从随机噪声变成了低分辨率图像 I^{LR} ，判别器D的输入是高分辨率图像 I^{HR} 。

□ 生成器G就不再是随机生成图像，而是根据一幅低分辨率图像生成一幅高分辨率图像，然后再送入判别器来判断输入图像是真实高分辨率图像还是生成的高分辨率图像。

SRGAN的对抗损失函数（误差函数）如下所示：

$$L_{Gen}^{SR} = \sum_{n=1}^N (-\log D_{\theta_D}(G_{\theta_G}(I^{LR})))$$

— 其中 θ_D, θ_G 分别表示判别器和生成器的参数, $D_{\theta_D}(G_{\theta_G}(I^{LR}))$ 表示判别器判断生成图片为真实高分辨率图像的概率。



图像超分辨率重建

□ 此外，SRGAN还使用了一种感知损失函数，这种损失函数用于让低分辨率图像和高分辨率图像的内容对齐，从而避免直接使用均方误差去寻找像素平均解，如下所示：

$$\bullet \quad L_{VGG/i,j}^{SR} = \frac{1}{W_{i,j}H_{i,j}} \sum_{x=1}^{W_{i,j}} \sum_{y=1}^{H_{i,j}} \left(\phi_{i,j}(I^{HR})_{x,y} - \phi_{i,j}(G_{\theta_G}(I^{LR}))_{x,y} \right)^2$$

- 其中 $\phi_{i,j}$ 表示在VGG-Net中第 i 个最大池化层之前通过第 j 次卷积（激活后）获得的特征图， $W_{i,j}H_{i,j}$ 表示对应卷积位置处VGG-Net输出的特征图的尺寸大小。
- 具体来说，首先把高分辨率图像送入VGG-Net进行退化，再把高分辨率图像退化出来的低分辨率图像送入SRGAN的生成器，并把生成器输出的高分辨率图像也送入VGG-Net。根据两幅高分辨率图像经VGG-Net第 i 层的中间结果逐像素求均方误差，就得到感知误差。



图像超分辨率重建

□ 将感知损失与判别器的对抗损失相加得到SRGAN的总损失函数：

$$\bullet L_{SR} = L_{VGG/i,j}^{SR} + \omega L_{Gen}^{SR}$$

— 其中 ω 为对抗损失的权重，一般设为 10^{-3} 。



图像超分辨率重建

□ 结果对比




Figure 6: **SRResNet** (left: a,b), **SRGAN-MSE** (middle left: c,d), **SRGAN-VGG2.2** (middle: e,f) and **SRGAN-VGG54** (middle right: g,h) reconstruction results and corresponding reference HR image (right: i,j). [4× upscaling]

图像超分辨率重建

□ 结果对比

Table 2: Comparison of NN, bicubic, SRCNN [8], SelfExSR [30], DRCN [33], ESPCN [47], **SRResNet**, **SRGAN**-VGG54 and the original HR on benchmark data. Highest measures (PSNR [dB], SSIM, MOS) in bold. [4× upscaling]

Set5	nearest	bicubic	SRCNN	SelfExSR	DRCN	ESPCN	SRResNet	SRGAN	HR
PSNR	26.26	28.43	30.07	30.33	31.52	30.76	32.05	29.40	∞
SSIM	0.7552	0.8211	0.8627	0.872	0.8938	0.8784	0.9019	0.8472	1
MOS	1.28	1.97	2.57	2.65	3.26	2.89	3.37	3.58	4.32
Set14									
PSNR	24.64	25.99	27.18	27.45	28.02	27.66	28.49	26.02	∞
SSIM	0.7100	0.7486	0.7861	0.7972	0.8074	0.8004	0.8184	0.7397	1
MOS	1.20	1.80	2.26	2.34	2.84	2.52	2.98	3.72	4.32
BSD100									
PSNR	25.02	25.94	26.68	26.83	27.21	27.02	27.58	25.16	∞
SSIM	0.6606	0.6935	0.7291	0.7387	0.7493	0.7442	0.7620	0.6688	1
MOS	1.11	1.47	1.87	1.89	2.12	2.01	2.29	3.56	4.46



音乐生成

- 与图像与文本相比，音乐可以说是一种特殊的语言，是表达人类思想感情、反映人类现实生活的一种艺术形式。
- GAN除了可用于图像生成之外，也适用于音乐的生成。典型的音乐生成方法有C-RNN-GAN和MuseGAN。




音乐生成

- ❑ C-RNN-GAN同样由一个生成器和一个判别器组成，只是生成器和判别器采用LSTM双向循环神经网络和全连接神经网络的组合结构。
- ❑ 由于数字乐器音乐往往使用MIDI格式进行不同乐器迁移，C-RNN-GAN的数据集使用四个实值标量对音乐信号的数据进行建模：音调长度、频率、强度和自上一个音调以来花费的时间。
- ❑ 因此，C-RNN-GAN的生成器使用随机变量生成一个由上述四值标量组成的四元组并送入判别器进行处理。
- ❑ C-RNN-GAN的结构如下图所示。

Mogren, Olof. "C-RNN-GAN: Continuous recurrent neural networks with adversarial training." *arXiv preprint arXiv:1611.09904* (2016).



音乐生成



音乐生成

□ C-RNN-GAN的生成器的输入是一组随机变量，而判别器的输入为上文中提到的由四个实值标量组成的四元组。C-RNN-GAN的损失函数与常见的GAN形式一样：

$$\bullet L_G = \frac{1}{m} \sum_{i=1}^m \log(1 - D(G(\mathbf{z}^{(i)})))$$

$$\bullet L_D = \frac{1}{m} \sum_{i=1}^m \left[-\log(D(\mathbf{x}^{(i)})) - \log(1 - D(G(\mathbf{z}^{(i)}))) \right]$$

- 其中 $\mathbf{z}^{(i)}$ 是 $[0,1]^k$ 中的均匀随机变量序列， $\mathbf{x}^{(i)}$ 为来自训练数据的四元组序列, k 为随机序列中数据的维度。



音乐生成

- ❑ 复调音乐（Polyphonic Music）中，音符用来组成和弦、琶音或旋律，因此仅考虑音符的时间顺序是不合适的。
- ❑ 在考虑基本假设和网络架构差异的情况下，MuseGAN提出了三个基于GAN框架的符号多音轨音乐生成模型：干扰模型、作曲家模型和混合模型，同时提出了一些生成音乐的评估标准（Metrics）。

Dong, Hao-Wen, Wen-Yi Hsiao, Li-Chia Yang, and Yi-Hsuan Yang. "MuseGAN: Multi-track sequential generative adversarial networks for symbolic music generation and accompaniment." In *Proceedings of the AAAI conference on artificial intelligence*, vol. 32, no. 1. 2018.



音乐生成

- 数据表示：MuseGAN将小节（Bar）作为作曲的基本单元，并选用了多音轨Piano-roll表示法，Piano-roll是一个二进制的、类似记分表的矩阵，表示音符在不同时间步长上的存在。一个M轨道的Piano-roll的一个小节表示为 $x \in \{0,1\}^{R \times S \times M}$ ，其中R和S分别表示一个小节的时间步长数和相关音符数。每个小节对应的矩阵/张量的大小都是固定的。




音乐生成

□ 音乐创作有两种常见的创作方式：演奏者即兴创作（Jamming）与作曲家统筹创作，MuseGAN设计了三个与这些创作方式相对应的多轨道相互依赖模型。


- 即兴创作模型中多个生成器独立工作，并且从私有随机变量 z_i 生成其自己曲目的音乐，同时这些生成器接受来自不同判别器的对抗损失信号进行训练。因此这种模型生成N个轨道的音乐需要N个不同的生成器和N个不同的判别器。
- 作曲家统筹创作模型中，一个单独的生成器生成一个多声道钢琴曲，每一个声道代表一个特定的音轨。这种模型只需要输入一个共享的随机向量 z 和一个单独的判别器用于直接判断多轨道音乐来自真实音乐还是生成器。



音乐生成



即兴创作模型




统筹创作模型

音乐生成

- 混合模型就是混合上述两种模型的模型，每个音轨一个生成器，接受独立的 z_i （Intra-track Random Vector）及全局的 z （Inter-track Random Vector）共同组合成的输入向量，同时共用一个判别器来判断来自真实音乐还是生成器。
- 与第二种方式相比，混合模式更加灵活，可以在生成器模型中使用不同的参数（如层数，卷积核大小等），将音轨的独立生成和全局和谐结合起来。



音乐生成



混合模型

音乐生成


- ❑ 以上三种模型只能逐小节生成多音轨音乐，而小节之间可能没有连贯性。因此需要一个时序模型来生成多小节音乐。
- ❑ MuseGAN给出了两种时态模型：从头（From Scratch）生成模型与条件音轨（Track-conditional）生成模型。



音乐生成

□ 小节连贯性（从头生成）模型将生成器分为两个子网络：
时序生成器 G_{temp} 和小节生成器 G_{bar}

- G_{temp} 将一个输入噪声 $\mathbf{z}$ 映射为一个携带了时序信息的隐藏变量序列 $\hat{\mathbf{z}} = \{\mathbf{z}^{(1)}, \mathbf{z}^{(2)}, \dots, \mathbf{z}^{(t)}\}$ 。
- 随后 $\hat{\mathbf{z}}$ 作为输入进入 G_{bar} 来产生对应的多音轨Piano-roll，这个过程可以表示为： $G(\mathbf{z}) = \{G_{bar}(G_{temp}(\mathbf{z}^{(t)}))\}_{t=1}^T$




音乐生成

□ 小节连贯性（条件音轨）模型给定一个人工设计音乐小节 y ，通过将此作为条件学习该小节的时间结构，并生成剩余完整小节（完成歌曲）

- 其中 G_{bar}^o 代表条件小节生成器，有两个输入，分别是 y 以及随机时间噪声 z 。为了保证生成小节的质量，额外引入了一个Encoder将 y 特征映射到 z 的特征空间上，这个过程可以表示为：

$$G^o(\mathbf{z}, \mathbf{y}) = \{G_{bar}^o(\mathbf{z}^{(t)}, E(\mathbf{y}^{(t)}))\}_{t=1}^T$$



音乐生成


□ 将多轨道相互依赖模型和时序模型组合即可得到最终的MuseGAN模型。

- 该模型共有四个输入：轨道间时序无关随机变量 $\mathbf{z}$ ，轨道内时序无关随机变量 $\mathbf{z}_i$ ，轨道间时序相关随机变量 $\mathbf{z}_t$ ，轨道内时序相关随机变量 $\mathbf{z}_{i,t}$ 。
- 对于每一个音轨 i ，共享时序模型 G_{temp} 和独立时序模型 $G_{temp,i}$ 分别将 $\mathbf{z}$ 和独立的 $\mathbf{z}_i$ 作为输入，得到的输出分别包含轨道间和轨道内的时序信息。
- $\mathbf{z}$ 和 $\mathbf{z}_i$ 经过时序模型的输出以及 $\mathbf{z}_t$ 、 $\mathbf{z}_{i,t}$ 共同进入小节生成器 G_{bar} 后产生音乐的小节来堆叠产生Piano-rolls。这个过程可以表示为：

$$G(\bar{\mathbf{z}}) = \left\{ G_{bar,i} \left(\mathbf{z}, G_{temp} \left((\mathbf{z}_t)^{(t)} \right), \mathbf{z}_i, G_{temp,i} \left((\mathbf{z}_{i,t})^{(t)} \right) \right) \right\}_{i,t=1}^{M,T}$$



音乐生成




异常检测

- ❑ 异常检测 (Anomaly detection) 是指识别和分类图像或其它数据中的异常物品、异常行为或异常数据。
- ❑ 传统的异常检测通常使用一些基于统计学的方法，如密度估计方法、聚类方法等，但这些方法通常需要足够多的异常先验知识，并且泛化能力容易受到数据分布的影响。
- ❑ GAN出现之后，人们开始使用它进行异常检测，取得了很好的效果。两个代表性工作是AnoGAN和GANomaly。



异常检测

- AnoGAN可以自动地检测图像中的异常部分，无需人工标注或先验知识。AnoGAN模型使用了一种称作“异常重构（Anomaly Reconstruction）”的方法，通过将随机噪声生成的图像重构成与输入图像相似的图像，然后通过计算两者的误差来检测异常数据。



Thomas Schlegl, Philipp Seeböck, Sebastian M. Waldstein, Ursula Schmidt-Erfurth, Georg Langs. "Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery." arXiv:1703.05921, 2017.



异常检测

□ AnoGAN包含以下三个组成部分：

- 生成器：AnoGAN使用生成器来生成与正常数据类似的样本。生成器接受一个随机向量作为输入，并输出生成的样本。通过使用正常数据训练生成器，它可以学习到正常数据的分布，并生成与之相似的样本。
- 判别器：判别器的作用是区分真实的正常数据与生成器生成的数据。它接受一个样本作为输入，并输出判断该样本是真实样本还是生成样本的概率。通过使用生成样本和真实样本训练判别器，它可以学习辨别生成样本与真实样本的区别。



异常检测

□ 异常重构：在训练完成后，AnoGAN使用了一种称为反向映射（Inverse Mapping）的技术来计算一个异常分数，用于衡量测试样本与训练样本之间的差异，分为以下三个步骤：

- 1) 从随机噪声 z 中生成一系列图像 x' ，其中有一张图像最接近于输入图像 x 。
- 2) 对于最接近输入图像的生成图像，计算其与输入图像之间的重构误差，误差越小，则生成的图像越接近于该输入图像。
- 3) 通过不断迭代，将重构误差定义为距离度量，找到输入图像周围最近的随机噪声，然后将其作为异常标记区域。



异常检测

□ AnoGAN的损失函数如下：


$$\bullet \text{ Loss} = (1 - \lambda)|f(x) - f(G(x))| + \lambda(x - G(x))$$

- 可以发现在测试阶段传入缺陷数据时最终的损失大，传入正常数据时的损失小，这时候就可以设置一个合适的阈值来判断图像是否有异常了。
- AnoGAN模型的优点是无需先验知识和标注数据，可以自动化地检测异常数据，且具有很好的可扩展性和可重复性。




异常检测

- 使用AnoGAN进行模型训练和异常检测的流程如图所示。
首先用正常数据训练获得模型，然后使用该模型对未知数据进行异常检测。



异常检测

- GANomaly在AnoGAN的基础上进行了改进，不再比较两个图像的分布，而是比较图像编码的潜在向量，如图所示。



Akay, Samet, Amir Atapour-Abarghouei, and Toby P. Breckon. "Ganomaly: Semi-supervised anomaly detection via adversarial training." In *Asian conference on computer vision*, pp. 622-637. Cham: Springer International Publishing, 2018.



异常检测

□ GANomaly在AnoGAN的基础上进行了改进，不再比较两个图像的分布，而是比较图像编码的潜在向量，如图所示。




Fig. 2. Pipeline of the proposed approach for anomaly detection.

Akcay, Samet, Amir Atapour-Abarghouei, and Toby P. Breckon. "Ganomaly: Semi-supervised anomaly detection via adversarial training." In *Asian conference on computer vision*, pp. 622-637. Cham: Springer International Publishing, 2018.



异常检测

- ❑ 具体来说，GANomaly的生成器并没有直接根据随机噪声采样生成数据，而是通过将输入数据编码成潜在向量再解码来生成数据，判别器则用来判断输入数据中哪些是正常的、哪些是异常的。
- ❑ 对于正常样本数据，编码、解码再编码得到的潜在向量和第一次编码得到的潜在向量差异不会特别大。
- ❑ 但是，使用基于正常样本训练好的编码器、解码器对未知的异常进行处理时，两者的差距往往是比较大的。




异常检测

- 通过将正常数据输入由编码器-解码器组成的生成器，可以得到对应输出空间中的生成数据。GANomaly的目标是学习从输入空间到输出空间的映射，同时也学习对抗损失。
 - 在这个过程中，如果一个输入数据 x 被生成器转换成输出数据 $\hat{x}$ ，并被判别器识别为正常数据，那么该输入就被认为是正常的。反之，如果一个输入数据 x 被转化成输出数据 $\hat{x}$ ，并被判别器识别为异常数据，则该输入数据被认为是异常的。



异常检测

□ 下图为AnoGAN与GANomaly的结构对比，可以直观看出GANomaly在AnoGAN基础上做出的改进。



异常检测

□ GANomaly与AnoGAN在损失函数上有所区别，如下所示：

$$Loss = \omega_1(L_{enc}) + \omega_2(L_{con}) + \omega_3(L_{adv})$$

- 其中 L_{enc} 指的是图像编码后的特征与图像编码、解码再编码后的特征差异， $L_{enc} = \|\mathbf{z} - \hat{\mathbf{z}}\|_2$ ；
- L_{con} 指的是原始图像和经过编码解码后的生成图像与原始图像之间的差异， $L_{con} = \|\mathbf{x} - \hat{\mathbf{x}}\|_1$ ；
- L_{adv} 指的是将原始图像和生成图像通过判别器后得到的正确概率的差异， $L_{adv} = \|f(\mathbf{x}) - f(\hat{\mathbf{x}})\|_2$ ； ω_1 、 ω_2 和 ω_3 分别是三项对应的权重。



异常检测

- GANomaly的优点是可以对输入数据进行端到端的学习，免去了大量的人工标注和处理异常数据的困难，可以很好地应用于异常检测、图像修复与补全等任务。





6

中英文术语对照

GAN产生背景

- ❑ 生成对抗网络: Generative Adversarial Networks, GAN
- ❑ 零和博弈: Zero-sum Game
- ❑ 生成器: Generator
- ❑ 判别器: Discriminator
- ❑ 动量: Momentum
- ❑ Kullback-Leibler散度: Kullback-Leibler Divergence, KL Divergence
- ❑ 循环一致性损失: Cycle Consistency Loss
- ❑ 域迁移: Domain Adaptation



GAN产生背景

- ❑ 图像生成: Image Generation
- ❑ 图像转换: Image Conversion
- ❑ 图像超分辨率重建: Image Super-Resolution Reconstruction
- ❑ 复调音乐: Polyphonic Music
- ❑ 异常检测: Anomaly Detection
- ❑ 异常重构: Anomaly Reconstruction
- ❑ 反向映射: Inverse Mapping



谢谢！



计算机科学与技术学院

SCHOOL OF COMPUTER SCIENCE AND TECHNOLOGY